

סיכום פרויקט – זיהוי כתב יד (OCR)

מערכת למידה עמוקה לזיהוי כתב יד · פרויקט בעיבוד תמונה

מטרת הפרויקט

פיתוח מערכת זיהוי תווים אופטי (OCR) מבוססת למידה עמוקה, הממירה תמונה של מילה בכתב יד לטקסט דיגיטלי. היעד ארוך הטווח הוא כתב יד של ילדים, המאופיין בשונות גבוהה: גדלי אותיות לא עקביים, שורות בסיס עקומות, מרווחים לקויים ואותיות מעוותות. המשימה היא בעיית תמלול רצף באורך משתנה, ללא חלוקה מפורשת לאותיות – ולכן נעשה שימוש במנגנון CTC.

מאגר הנתונים

- מקור:** מאגר IAM ברמת מילים (מ-HuggingFace).
- חלוקה:** 69,200 אימון / 23,100 ולידציה / 23,100 מבחן.
- סטטיסטיקת תוויות (אימון):** אורך מילה ממוצע 4.1 תווים, מקסימום 53.
- מגבלה מרכזית:** IAM הוא כתב יד של מבוגרים. לכן דיווחנו על בסיס העברה (transfer baseline) על נתוני מבוגרים, והשתמשנו בהגברת נתונים ו-STN כדי לבנות עמידות לעיוותים אופייניים לילדים.

עיבוד מקדים (Pre-processing)

המרה לגווני אפור ← סף אדפטיבי גאוסייני (בינאריזציה עמידה לתאורה לא אחידה) ← סינון רעש (Median blur) ← שינוי גודל ל- 32×128 תוך שמירת יחס ← נרמול לטווח $[-1, 1]$.

שלושת השלבים (Milestones)

שלב 1 – מודל בסיס (CRNN): ארכיטקטורה קלאסית – CNN לחילוף מאפיינים ← BiLSTM דו-כיווני ← שכבת CTC. כ-8.2 מיליון פרמטרים, 53 מחלקות. יצירת מדדי פתיחה להשוואה.

שלב 2 – ארכיטקטורה מתקדמת + הגברת נתונים:

- Spatial Transformer Network (STN):** רשת הלומדת טרנספורמציה אפינית ליישור הטקסט (שיפוע, גודל, שורת בסיס) לפני הזיהוי. מאותחלת כזהות, ולכן האימון מתחיל מהתנהגות מודל הבסיס. תוספת של כ-80 אלף פרמטרים בלבד.
- הגברת נתונים מותאמת (Augmentation):** סיבוב, גזירה (shear), עיוות אלסטי ושורת בסיס גלית – המדמים עיוותים של כתב ילדים, ומוחלים על סט האימון בלבד.

שלב 3 – כוונן עדין והערכה סופית: כוונן עדין (Fine-tuning) של מודל שלב 2 עם קצב למידה נמוך פי 10, והערכה ראשונה על **סט המבחן** (test set). נבנה גם צינור הרצה (inference pipeline) נקי:

```
python -m src.inference
```

תוצאות

מודל	CER ולידציה	WER ולידציה	CER מבחן	WER מבחן
שלב 1 - בסיס CRNN	0.1065	0.2460	-	-
שלב 2 - STN-CRNN + הגברה	0.0867	0.2012	0.0981	0.2234
שלב 3 - לאחר כוונן עדין	0.0903	0.2099	0.0969	0.2215

- שיפור עיקרי (שלב 1 ← 2): הפחתה של כ-18.6% ב-CER ו-1,036 מילים נוספות שזוהו במדויק.
- כוונן עדין (שלב 2 ← 3): שיפור קטן ועקבי על סט המבחן (CER מ-0.0981 ל-0.0969).
- מודל סופי: CER 0.0969 על סט המבחן, **77.9% מהמילים זוהו בצורה מושלמת**.

ניתוח שגיאות

השגיאות עם ה-CER הגבוה ביותר הן כמעט תמיד תוויות של תו בודד או סימני פיסוק (, , . , a) - זהו **ארטיפקט של המדד** (מרחק עריכה חלקי אורך תווית באורך 1), ולא חולשה אמיתית. על מילים אמיתיות המודל חזק (כ-80% דיוק מלא). הכשלים האמיתיים הם חיתוכים מעוותים או מטושטשים.

מסקנות ועבודה עתידית

מודל CRNN קלאסי נותן בסיס העברה טוב; הוספת STN והגברת נתונים משפרת אותו בכ-18.6% בעלות פרמטרים זניחה, וכוונן עדין נותן את המודל הסופי. הצעד הבא המשמעותי ביותר: **מאגר מתויג של כתב יד של ילדים** לכוונן בתוך הדומיין, וכן פענוח מסוג beam search עם מודל שפה להפחתת WER.